

插值和逼近

本章介绍插值与逼近，即寻找某个逼近复杂函数 $f(x)$ 的简单函数 $p(x)$ 。

代数插值

代数插值共介绍了三种插值方法：**范德蒙矩阵方法**、**拉格朗日插值方法**、**牛顿插值方法**。三种插值方法代码实践写在了 `Interpolation.py` 中。其中范德蒙矩阵方法是最直接但计算量最大的方法，但是需要求解一组 n 次的线性方程组， n 为插值点个数。拉格朗日插值方法易于理解，包括拉格朗日基+各个基对应的函数值，可以参考视频：[B站轩兔](#)，但是其缺陷在于若需要额外添加一个新的插值项，则需要重新计算所有的拉格朗日基。牛顿法避免了拉格朗日法的问题，需要通过函数的 n 阶差商作为系数，和牛顿基的形式完成插值。

范德蒙矩阵方法

给定 $n + 1$ 个插值点 $(x_i, y_i = f(x_i))$ ，构造 n 次插值多项式 $p_n(x)$ 逼近 $f(x)$ ：

$$p_n(x) = a_0 + a_1x + a_2x^2 + \cdots + a_nx^n$$

那么可以构建 $n + 1$ 个线性方程组：

$$\begin{aligned} a_0 + a_1x_0 + \cdots + a_nx_0^n &= y_0 \\ a_0 + a_1x_1 + \cdots + a_nx_1^n &= y_1 \\ &\vdots \\ a_0 + a_1x_n + \cdots + a_nx_n^n &= y_n \end{aligned}$$

通过求解上述线性方程组，从而确定系数 $a_0 \cdots a_n$ ，从而构造 $p_n(x)$ 的方法即为范德蒙矩阵方法。

拉格朗日插值法

拉格朗日插值法定义下述插值多项式 $p_n(x)$ ：

$$p_n(x) = \sum_{k=0}^n l_k(x) f(x_k)$$

其中 $l_k(x)$ 称为拉格朗日Lagrange基函数，其表达式为：

$$l_k(x_i) = \begin{cases} 1, & i = k \\ 0, & i \neq k \end{cases}$$

即除了插值的点 x_k 外，其的插值点都为零的光滑函数，这个基函数可这样构造：

$$\prod_{j=0, j \neq k}^n \frac{x - x_j}{x_k - x_j}$$

上述即为拉格朗日插值法。

牛顿插值法

牛顿插值法的多项式有以下的形式，这样的好处是多一个额外的插值点可以在原有的基础上增加一项，而不需要推倒重来：

$$P_n(x) = a_0\omega_0(x) + a_1\omega_1(x) + \cdots + a_n\omega_n(x) = \sum_{i=0}^n a_i\omega_i(x)$$

其中 $\omega_i(x)$ 为牛顿插值基函数，有：

$$\begin{cases} \omega_0 = 1 \\ \omega_n = (x - x_0)(x - x_1) \cdots (x - x_{n-1}) = \prod_{j=0}^{n-1} (x - x_j) \end{cases}$$

式中的 a_i 为牛顿插值法的系数，通过差商的方法定义：

$$\begin{cases} a_0 = f(x_0) \\ a_k = f[x_0 \cdots x_k] \end{cases}$$

其中差商的定义：

$$\begin{aligned} f[x_0, x_1] &= \frac{f(x_1) - f(x_0)}{x_1 - x_0} \\ f[x_0, \cdots, x_k] &= \frac{f[x_0, \cdots, x_{k-2}, x_k] - f[x_0, \cdots, x_{k-1}]}{x_k - x_{k-1}} \end{aligned}$$

三种插值余项

对于一个插值函数，其余项定义为 $R_n(x) = f(x) - P_n(x)$

拉格朗日余项

这是由**罗尔定理**直接推算得到的形式，但是需要知道具体函数的形式并进行求导，在这里， ξ 是插值区间内的未知点：

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \cdot \omega_{n+1}(x)$$

牛顿余项

若没有具体的函数或不可导，可以使用牛顿余项的差商形式表示：

$$R_n(x) = f[x_0, x_1, \dots, x_n, x] \cdot \omega_{n+1}(x)$$

后验估计余项

上述的情况必须要求知道函数的一些具体的信息，若只有某个未知函数的离散数据，我们可以在完成插值后，考虑替换或加密（变密集）原先的节点，得到新的某个节点 \tilde{x}_n ,然后重新进行插值得到 $\tilde{P}_n(x)$ ：

$$R_n(x) = \frac{x - x_n}{x - \tilde{x}_n} (P_n(x) - \tilde{P}_n(x))$$

这个式子可以由拉格朗日余项简单推导得到，并考虑 \tilde{P}_n 和 P_n 的导数相同。

分段低次插值

在实际工程中，计算大量的 n 个节点构成的函数计算量较大，可以将原函数分段，然后使用例如二次低次插值等方法。分段低次插值获得了收敛性，但损失了光滑性。

Hermite插值

给定 $n + 1$ 个节点 $x_0 \cdots x_i$ ，并给定 m 个导数信息，构建不高于 $m + n + 1$ 的多项式：

$$H(x) = \sum_{j=0}^{m+n+1} a_j x^j$$

使其能够满足：

$$\begin{cases} H(x_i) = y_i \\ H'(x_{i_k}) = y'_{i_k} \end{cases}$$

上述即为Hermite多项式。

为了构造Hermite多项式，可以先用代数插值的方法求出满足函数位置条件的 $p_n(x)$ ，然后这样构造：

$$H(x) = p_n(x) + q_m(x)\omega_{n+1}(x)$$

为了补充函数的导数信息，可以补充对上式求导，整理可以发现：

$$q_m(x_{j_k}) = \frac{y'_{j_k} - p'_n(x_{j_k})}{\omega'_{n+1}(x_{j_k})}$$

对于Hermite多项式的误差估计，有：

$$R(x) = \frac{f^{(n+m+2)}(\epsilon)}{(n+m+2)!} \omega_{n+1}(x) \prod_{k=0}^m (x - x_{i_k})$$

正交多项式

基本概念

权函数

对于区间 (a, b) 上的非负连续函数 $f(x)$ ，若

$$\int_a^b \rho(x) f(x) dx = 0$$

则在 (a, b) 上 $f(x) \equiv 0$ ， $\rho(x)$ 即为区间上的权函数。

内积

$$(f, g) = \int_a^b \rho(x) f(x) g(x) dx$$

为函数 $f(x)$ 于 $g(x)$ 在 $[a, b]$ 上的内积。

正交多项式系

若 $(f, g) = 0$ ，则称 $f(x)$ 与 $g(x)$ 在区间 $[a, b]$ 上带权正交。

若函数系 $\{\phi_0, \phi_1, \dots, \phi_n\}$ 满足:

$$(\phi_i, \phi_j) = \begin{cases} 0, i \neq j \\ a_i > 0, i = j \end{cases}$$

则称 $\{\phi_k(x)\}$ 为 $[a, b]$ 上带权 $\rho(x)$ 的正交函数系。

常用的正交多项式系

勒让德Legendre多项式，在区间 $[-1, 1]$ 上正交：

$$\begin{cases} L_0(x) = 1 \\ L_n(x) = \frac{1}{2^n n!} \cdot \frac{d^n}{dx^n} [(x^2 - 1)^n] \end{cases}$$

注：学习轨道力学的非球形引力摄动中使用到了连带勒让德函数，其表达式为：

$$L_n^m(x) = (1 - x^2)^{\frac{m}{2}} \cdot \frac{d^m}{dx^m} P_n(x)$$

这是上述勒让德多项式的一个拓展，即 $m = 0$ 时， $L_n^m(x) = L_n(x)$ 。

函数的最佳平方逼近

本节的概念与最小二乘法类似，不过用内积来定义最佳平方逼近元素，使用连续的函数 $p(x)$ 逼近另外一个复杂的连续函数 $f(x)$ ：

给定一组函数组作为基底，并张成线性空间 $H_n = \text{Span}\{\phi_0, \phi_1, \dots, \phi_i\}$

$$(f - p^*, f - p^*) = \min_{p \in H_n} (f - p, f - p)$$

则称 $p^*(x)$ 为子空间 H_n 中对 $f(x)$ 的最佳平方逼近元素。

为了求解 $p^*(x)$ 对上述变型可以得到：

$$p^*(x) = \sum_{k=0}^n c_k^* (\phi_k, \phi_j) = (f, \phi_j)$$

而我们实际上就要求解的即为上述式子中所有的 c_k^* 系数。

正则方程求解最佳平方逼近

以书中的例题为例，求解 $H_1 = \text{Span}\{1, x\}$ 中对于 $f(x) = \sqrt{x}$ 的最佳平方逼近元素 $p(x)$ ：

首先给出了这里的内积的定义方式：

$$(f, g) = \int_0^1 f(x)g(x)dx$$

然后求解所有项的内积：

$$\begin{aligned}\varphi_0(x) &\equiv 1, & \varphi_1(x) &= x \\ (\varphi_0, \varphi_0) &= \int_0^1 dx = 1, & (\varphi_1, \varphi_0) &= \int_0^1 x dx = \frac{1}{2} \\ (\varphi_1, \varphi_1) &= \int_0^1 x^2 dx = \frac{1}{3}, & (\varphi_0, f) &= \int_0^1 \sqrt{x} dx = \frac{2}{3} \\ (\varphi_1, f) &= \int_0^1 x \sqrt{x} dx = \frac{2}{5}\end{aligned}$$

最后形成一个这样的线性方程组：

$$\begin{bmatrix} (\phi_0, \phi_0) & (\phi_1, \phi_0) \\ (\phi_0, \phi_1) & (\phi_1, \phi_1) \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \end{bmatrix} = \begin{bmatrix} (\phi_0, f) \\ (\phi_1, f) \end{bmatrix}$$

代入上述数字可以解得： $c_0 = 4/15, c_1 = 4/5$, 因此：

$$p^*(x) = c_0 \phi_0 + c_1 \phi_1 = \frac{4}{15} + \frac{4}{5}x$$

利用正交函数系求解最佳平方逼近

在使用正则方法求解上述方程式若方程组较大则会病态，因此可以利用**正交函数系**求解最佳平方逼近避免这个问题。

以使用勒让德多项式求解为例，此时最佳平方逼近的系数可直接这样求解得到：

$$c_k^* = \frac{(f, L_k)}{L_k, L_k}$$

若给定的求解区间为一般的 $[a, b]$ 而非 $[-1, 1]$, 可以这样转化：

$$x = \frac{a+b}{2} + \frac{b-a}{2}t$$

最小二乘法补充

先前学习过最小二乘法的一般表达式：

假设给定一组离散的观测值 $\hat{\mathbf{y}}_{t \times n}$ ，需要使用函数 $\mathbf{A}\mathbf{x}$ 逼近。其中 $\mathbf{A}_{t \times p}$ 为基构成的矩阵，我们要求解系数矩阵 $\mathbf{x}_{p \times n}$ 完成最小二乘法，即：

$$\min_{\mathbf{x}} ||\hat{\mathbf{y}} - \mathbf{A}\mathbf{x}||$$

若 \mathbf{A} 不为方阵，为了求解 \mathbf{x} , 需要用到伪逆的方法求解，注意这里需要满足矩阵 \mathbf{A} 满秩：

$$\mathbf{x} = \mathbf{A}^\times \hat{\mathbf{y}} = [(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T] \hat{\mathbf{y}}$$

实际上这个表达式也可写成：

$$\mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{A}^T \hat{\mathbf{y}}$$

在部分情况下解题比较方便。